Aprendizagem de Máquina
AULA 9

Prof. Dr. Rooney R. A. Coelho

PUC-SP

Redes Neurais Convolucionais

Motivação

Em maio de 2013, o Google lançou a pesquisa de fotos pessoais, oferecendo aos usuários a capacidade de recuperar fotos nas bibliotecas com base nos objetos presentes nessas imagens.

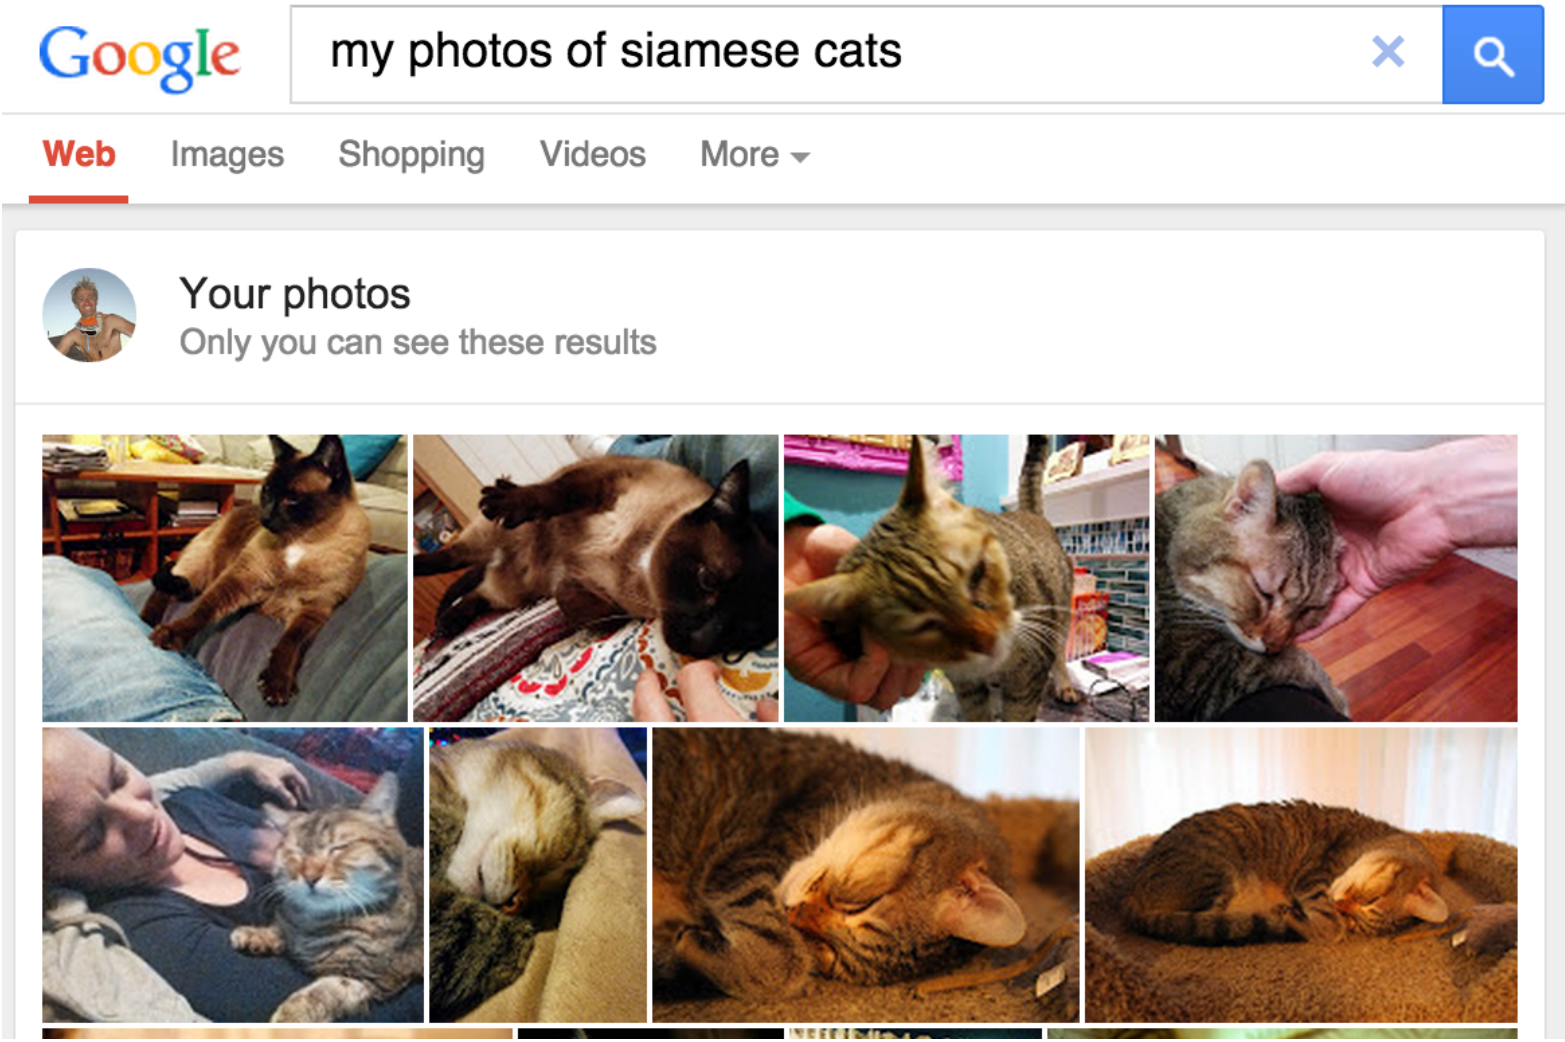

Google Fotos

O recurso, mais tarde incorporado ao Google Fotos em 2015, foi amplamente percebido como um divisor de águas, uma prova de conceito de que o software de visão computacional poderia classificar as imagens em padrões humanos, agregando valor de várias maneiras:

- Os usuários não precisavam mais marcar fotos com rótulos como “#praia" para categorizar o conteúdo de imagens. Isso elimina uma tarefa manual que poderia ser bastante tediosa ao gerenciar conjuntos de centenas ou milhares de imagens.
- Os usuários podem explorar a coleção de fotos de novas maneiras, usando termos de pesquisa para localizar fotos com objetos que talvez nunca tenham sido marcados. Por exemplo, eles podem pesquisar “palm tree" para exibir todas as fotos de férias que têm palmeiras no fundo.
- É possível que o software possa "ver" distinções fiscais que os próprios usuários finais podem não conseguir perceber (por exemplo, distinguir gatos siamês e abyssinianos), aumentando o conhecimento dos usuários.

stuffed toy	0.799
plush	0.763
wool	0.693
textile	0.682
fur	0.678
animal	0.612
dog like mammal	0.504

Redes Neurais Convolucionais

Introdução

Introdução

- As redes neurais convolucionais (CNNs) são uma família de redes profundas que podem explorar a estrutura espacial dos dados (por exemplo, imagens) para aprender sobre esses dados, permitindo que o algoritmo produza algo útil.
- As CNNs são capazes de identificar características locais em uma imagem (como olhos, nariz, boca, etc.), o que é feito em camadas de convolução.
- Com base nessas características locais, a CNN produzirá padrões de ativação específicos que representam globalmente a presença dessas características, que são produzidos em camadas totalmente conectadas.
- Por exemplo, se a imagem é de uma pessoa, a CNN produzirá um padrão de ativação diferente do que para uma imagem sem uma pessoa.

Introdução

- Uma CNN típica possui três componentes principais: camadas de convolução, camadas de pooling e camadas totalmente conectadas.
- As camadas de convolução consistem em vários kernels (também chamados de filtros de convolução) que aprendem características locais em uma imagem (por exemplo, como um olho de uma pessoa parece) e convolvem essas características sobre a imagem, produzindo um mapa de ativação.
- O mapa de ativação produz um valor alto em uma determinada localização se a característica representada no filtro de convolução estiver presente nessa localização da entrada.

Introdução

- As camadas de pooling tornam as características aprendidas pela CNN invariáveis à tradução, o que significa que a saída da camada de pooling será a mesma independentemente da posição exata da característica na imagem.
- As camadas totalmente conectadas são responsáveis por produzir diferentes padrões de ativação com base nos conjuntos de mapas de características ativados e nas localizações da imagem em que esses mapas de características são ativados.

Introdução

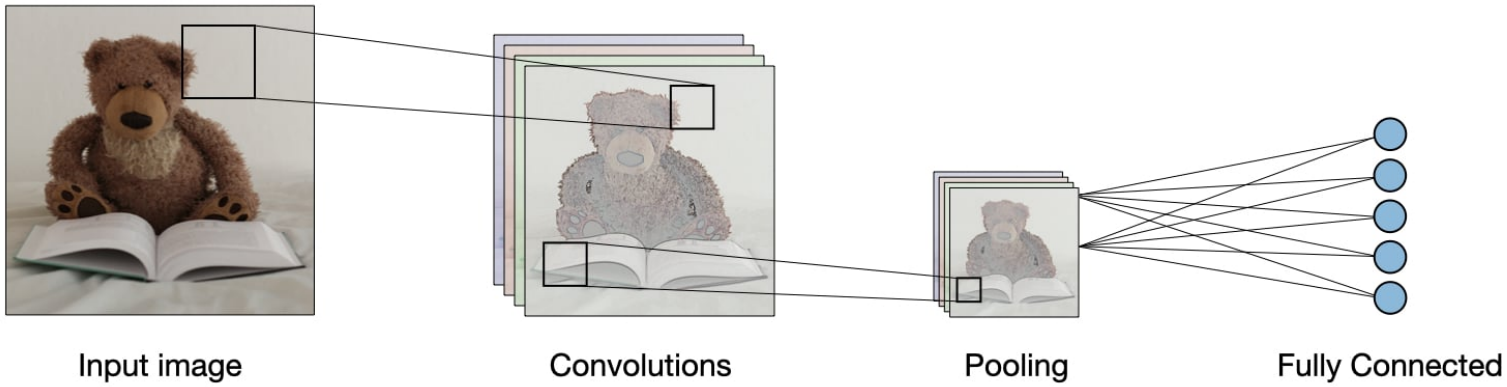

Tunnel Vision

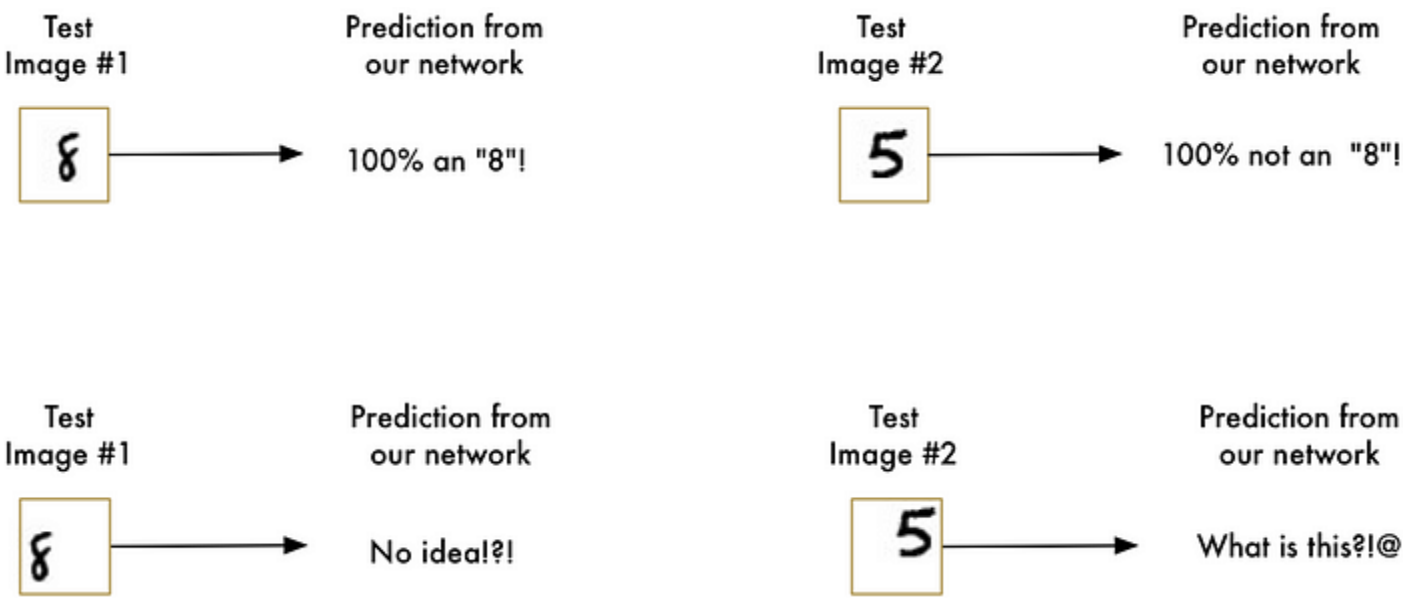

Convolução

- Convolução é um processo utilizado em redes neurais convolucionais (CNNs)
- Durante uma convolução, filtros são aplicados a blocos do mapa de recursos de entrada para produzir um mapa de recursos de saída
- Os filtros deslizam sobre a grade do mapa de recursos de entrada, extraindo cada bloco correspondente
- A profundidade do mapa de recursos de saída corresponde ao número de filtros aplicados
- É possível adicionar padding para manter as mesmas dimensões do mapa de recursos de entrada
- Durante o treinamento, a CNN aprende os valores ideais para as matrizes de filtro para extrair atributos significativos do mapa de atributos de entrada
- O número de filtros adicionados à rede afeta o tempo de treinamento e o valor incremental fornecido por cada filtro subsequente

Camada de convolução

- A camada de convolução realiza uma operação que produz um valor alto para uma determinada posição se a característica de convolução estiver presente nessa localização, caso contrário, produz um valor baixo.
- Essa operação de convolução é realizada multiplicando cada valor da célula do kernel pelo valor correspondente do pixel da imagem que se sobrepõe à célula do kernel e, em seguida, somando esses resultados.
- O valor exato é calculado usando uma fórmula que leva em conta a largura e altura do kernel, a imagem de entrada e o próprio kernel.
- A operação de convolução pode ser visualizada como uma transformação aplicada à imagem, que pode resultar em vários efeitos (por exemplo, extração de bordas, desfoque, etc.).
- A saída da camada de convolução pode ser visualizada como uma imagem binária que se ilumina nas áreas em que a característica está presente.
- A camada de convolução é uma das principais componentes de uma CNN, e é responsável por aprender características locais da imagem.

Camada de convolução

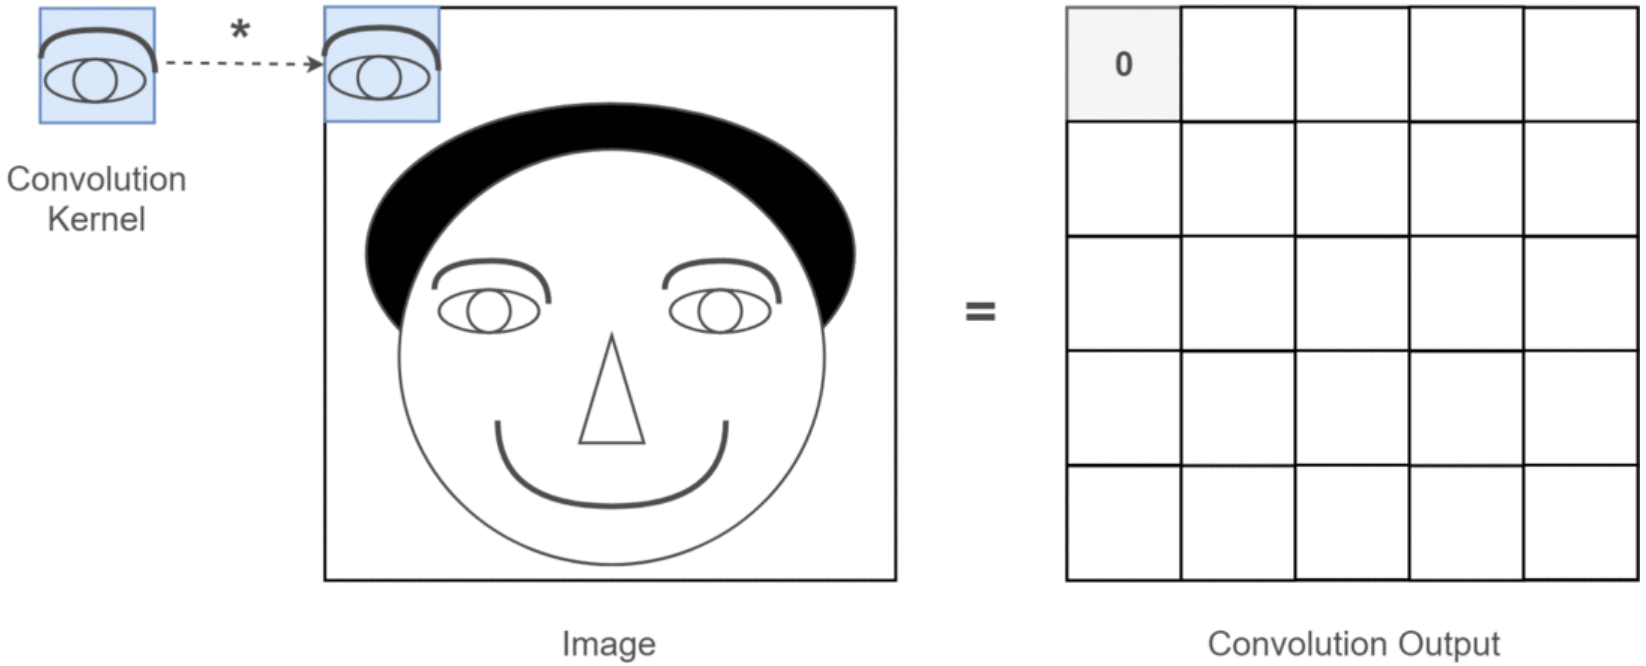

Camada de convolução

0	0	0	0	0
0	0	0	0	0
0	100	0	100	0
0	0	0	0	0
0	0	0	0	0

Convolution Output

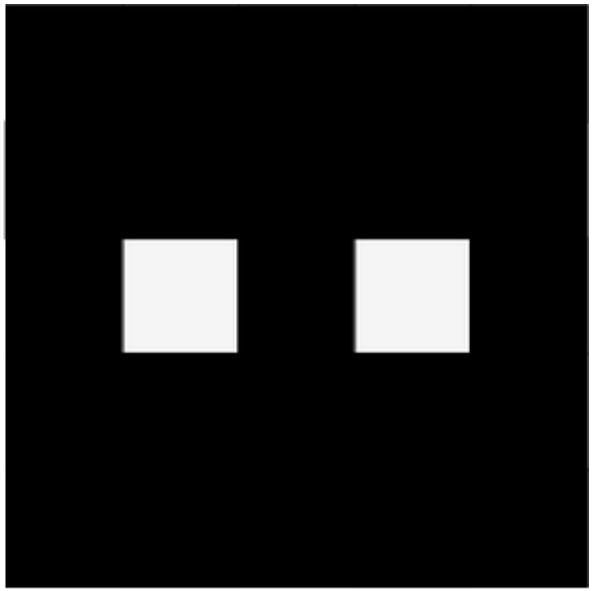

Convolution Output
(as an Image)

Camada de Pooling

- Aplica-se uma etapa de pooling para reduzir o número de dimensões do mapa de recursos
- O algoritmo mais comum para pooling é o pool máximo
- O pool máximo extrai blocos do mapa de recursos e gera um novo mapa de atributos com o valor máximo de cada bloco
- Os parâmetros do pool máximo são o tamanho do filtro e o passo (distância que separa cada bloco extraído)
- O pool máximo preserva apenas os valores máximos de cada bloco, reduzindo o tamanho do mapa de recursos resultante

Camada de Pooling

- Ela é responsável por tornar a CNN um pouco invariante à translação em termos da saída da convolução.
- **O objetivo do Pooling é reduzir o tamanho da entrada e tornar a CNN invariante à translação.**
- O Pooling pode ser realizado com um deslocamento de 1 pixel de cada vez (Stride = 1) ou com um deslocamento de 2 pixels de cada vez (Stride = 2).
- O Stride de 2 é conhecido como Strided-Pooling.
- A operação de Pooling produz o mesmo mapa de características para imagens idênticas, mas transladadas ligeiramente.

Camada de Pooling

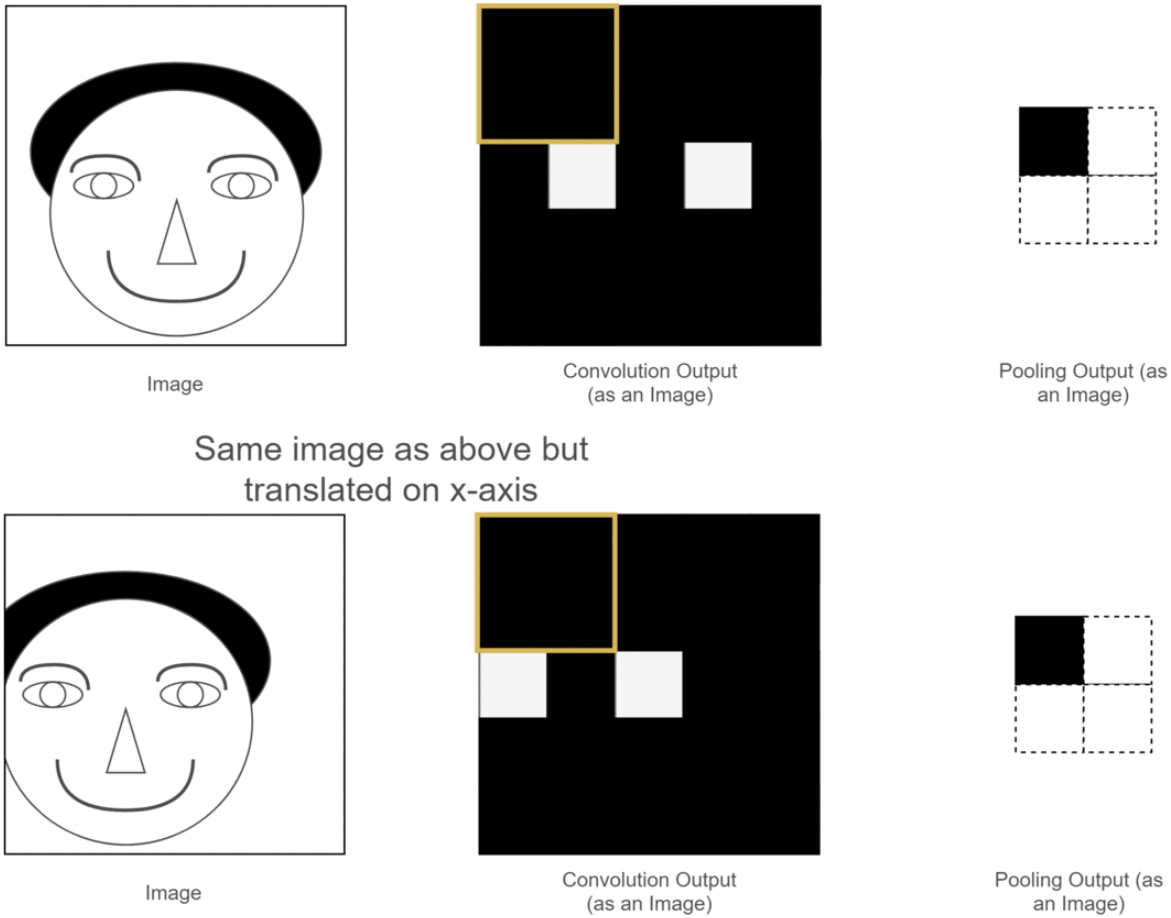

Camadas Totalmente Conectadas

- As camadas totalmente conectadas combinam as características aprendidas por diferentes convoluções, para que a rede possa construir uma representação global da imagem como um todo.
- As camadas totalmente conectadas são colocadas no final da rede neural convolucional (CNN).
- Os neurônios nas camadas totalmente conectadas são ativados com base em quais entidades representadas pelas características das convoluções estão presentes na entrada.
- Quando os neurônios totalmente conectados são ativados, eles produzem diferentes padrões de ativação com base nas características presentes nas imagens de entrada.
- Isso fornece uma representação compacta do que existe na imagem para a camada de saída, que pode usá-la facilmente para classificar corretamente a imagem.

Integrando tudo para formar o modelo final

- As camadas de convolução aprendem diferentes características locais nos dados, como a aparência de um olho.
- A camada de pooling torna a CNN invariante a translações dessas características, permitindo que a CNN reconheça a mesma característica mesmo que apareça ligeiramente transladada em duas imagens diferentes.
- As camadas totalmente conectadas processam as características aprendidas e produzem a saída da rede.
- Adicionar mais camadas aumenta o desempenho da rede, permitindo que ela aprenda características de forma hierárquica, como a aparência de bordas, formas básicas e formas mais avançadas como olhos e narizes.
- Para treinar a CNN, é necessário definir uma função de custo que recompensa a identificação correta dos dados e penaliza a classificação incorreta.
- Otimizamos os pesos das características para refletir recursos úteis que levam a CNN a identificar corretamente uma imagem.
- O treinamento da CNN é realizado através do processo de retropropagação do gradiente.
- Para implementar uma CNN, geralmente usamos bibliotecas de deep learning, como TensorFlow ou PyTorch, que implementam essas operações de diferenciação internamente.

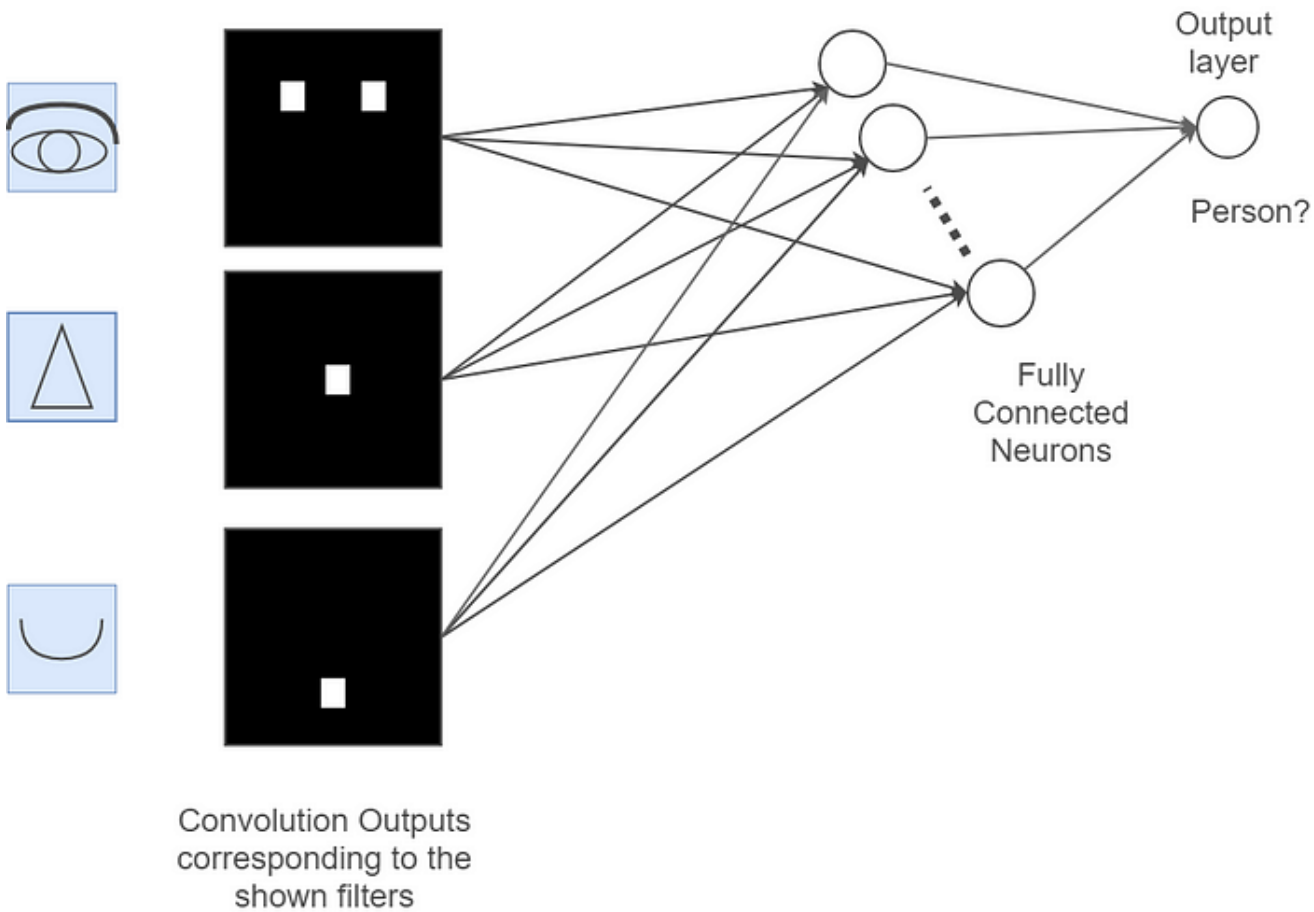
Output
layer
Person?
Fully
Connected
Neurons
Convolution Outputs
corresponding to the
shown filters

Overfitting

- Overfitting é um problema comum em modelos de machine learning, incluindo redes neurais convolucionais
- O overfitting ocorre quando o modelo é ajustado demais aos dados de treinamento, tornando-se incapaz de generalizar para novos exemplos
- Duas técnicas para evitar o overfitting em uma CNN são o aumento de dados e a regularização de dropout
- O aumento de dados envolve a criação de novas variantes de imagens atuais, aumentando artificialmente a diversidade e o número de exemplos de treinamento
- A regularização de dropout envolve a remoção aleatória de unidades da rede neural durante o treinamento, o que impede que o modelo se torne muito dependente de unidades específicas e aumenta a capacidade de generalização

Data Augmentation

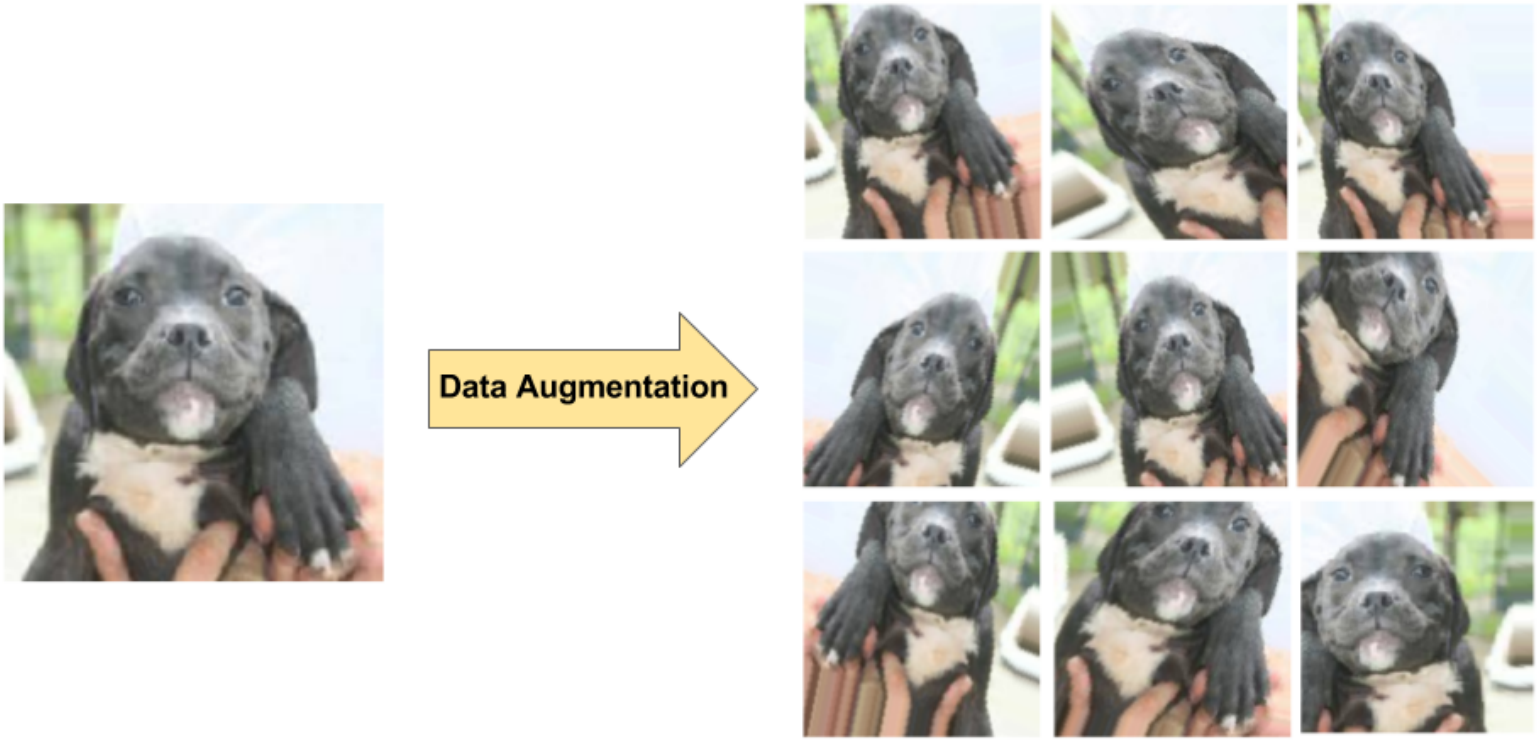

Original	Flip	Rotation	Random crop
• Image without any modification	• Flipped with respect to an axis for which the meaning of the image is preserved	• Rotation with a slight angle • Simulates incorrect horizon calibration	• Random focus on one part of the image • Several random crops can be done in a row

Color shift	Noise addition	Information loss	Contrast change
• Nuances of RGB is slightly changed • Captures noise that can occur with light exposure	• Addition of noise • More tolerance to quality variation of inputs	• Parts of image ignored • Mimics potential loss of parts of image	• Luminosity changes • Controls difference in exposition due to time of day

Como aproveitar um modelo?

- Treinar uma CNN para classificação de imagens pode levar muito tempo e requer uma grande quantidade de dados de treinamento
- É possível aproveitar modelos pré-treinados em grandes conjuntos de dados para adaptá-los para uso em tarefas de classificação específicas
- Uma técnica comum é a extração de atributos, onde as representações intermediárias produzidas pelo modelo pré-treinado são recuperadas e alimentadas em um novo modelo como entrada
- A extração de atributos envolve alimentar imagens de treinamento em um modelo pré-treinado e extrair os atributos da camada de convolução final
- Para melhorar o desempenho com a extração de atributos em um modelo pré-treinado, é comum ajustar os parâmetros de peso aplicados aos atributos extraídos